室内 RF Map 数据与网络训练指导

项目目标：将房间内部分位置的实测 RSSI 输入已训练的网络，一次输出整张二维信号强度地图。二维地图对应固定接收高度，房间范围和测点坐标由人工提供，第一版不要求输入详细家具布局。网络预测数值，软件再将数值绘制成热力图。

数据怎样采集

固定路由器的位置和配置，将 ESP32 移动到房间不同位置采集指定 AP 的 RSSI。各点保持相同接收高度和朝向，连续记录一段时间，以统一的均值或中位数作为该点代表值，同时保留波动情况。记录房间边界、测点坐标、AP 标识、时间及部署条件，注意操作人员遮挡和环境变化。CSI 可以同步保存，本项目第一版以 RSSI 为预测目标。

每一种固定部署条件形成一份参考地图数据。测点应覆盖房间不同区域，并保留用于检验预测的额外位置。参考地图不必测满每个网格，但需要足够的已测位置，能够分出网络输入点和监督点。不要用插值结果充当实测答案。

准备多份独立参考地图，例如在同一房间改变路由器位置后重新测量，并将同一部署的重复采集归为一组。若只有一张固定地图，反复遮挡只能用于程序调试，不能证明模型学会了未知地图补全。同房间新部署的测试，也不能代替跨房间测试。

训练集和测试集怎样划分

先按独立场景组划分训练集、验证集和测试集，再对每张地图抽取测点。训练集更新模型参数，验证集选择模型和停止训练，测试集只做最终评估。同一参考地图的重复记录和不同遮挡版本必须放在同一集合；需要检验跨房间能力时，按房间整体留出。

每张图内部再分“输入点”和“隐藏实测点”。输入点的位置与 RSSI 提供给网络；隐藏实测点不进入输入，训练时用作监督，测试时用来计算误差。训练可反复改变抽点方式，验证和测试应固定并保存抽点结果，保证三个网络公平比较。

数据怎样变成网络输入

将坐标映射到规则网格，输入包括稀疏 RSSI 图、观测位置标记图和房间有效区域图。未测位置只是占位值，不能被理解为零信号。统一物理网格间距与接收高度，房间外使用填充标记；标准化参数只从训练集计算并保存。输出为同尺寸的单通道 RSSI 网格。

可尝试的三个网络方案

统一使用 PyTorch，先跑通基础结构，再比较改进。公开网络结构可以用真实数据重新训练，但原仓库的数据格式、监督方式和已有权重不能直接照搬。以下第三种是 U-Net 的工程变体，不是另一篇论文的原样复现。

方案一 卷积补全自编码器

编码器提取稀疏观测的空间特征，解码器恢复整张地图。输入为 RSSI、观测标记和区域标记，输出为连续 RSSI。采用小型卷积结构，先建立能训练、能预测的基线。重点参考论文中“部分实测作输入、其他实测作监督”的训练方法。

方法参考 Deep Completion Autoencoders 真实数据训练章节

代码与使用说明 RF 地图补全 PyTorch 工程

方案二 小型 U Net

在编码器和解码器之间增加跳跃连接，保留更多空间信息，建议作为主模型。可使用 segmentation_models_pytorch，设置三个输入通道、一个输出通道和线性输出，使用回归损失。先采用较小网络，不必直接引入复杂注意力或大型预训练模型。

框架代码 segmentation_models_pytorch

入门教程 官方 Quick Start

参数说明 U Net 输入与输出配置

方案三 插值引导残差 U Net

只根据本次输入点生成初始插值图 B，再让 U-Net 预测修正量，最终输出为“B 加修正量”。输入在方案二基础上增加 B。初始图与网络输出使用同一数值尺度。每次更换输入点必须重新插值，不能使用隐藏监督点生成 B。单独保留纯插值结果，检验网络是否真正改善预测。

结构与实现说明 两阶段地图补全及插值加 U Net

上述项目可借鉴结构和训练流程；残差输出是本项目可尝试的实现方式，需要自行验证。前两个模型先使用相同的数据接口，第三个仅增加初始插值图，避免同时更改多项条件。

通用训练教程

PyTorch 官方入门 数据加载 网络定义 训练和模型保存

教程中的示例任务可能是分类或分割；本项目应改成连续 RSSI 回归，不能原样使用分类标签、交叉熵或 softmax 输出。

怎样训练 评估与交付

训练方法

每次从训练场景中抽取部分实测点作为输入，让网络输出整张图。只在未提供给网络的隐藏实测点上计算预测与实测 RSSI 的均方误差，并按有效监督点数量归一化。完全未测的位置和房间外的位置不参与损失，输入点也不能代替隐藏点的补全监督。

先用少量固定训练样本检查误差能否下降，再开展正式训练。所有模型共用数据划分和评价规则，分别保存训练与验证曲线，依据验证集选择最佳权重。训练时改变输入点数量和分布，但应与实际使用方式相近；具体配置根据预实验决定。测试集不得参与调参。

训练误差低而验证误差高时，应检查过拟合、独立场景数量和数据差异；结果异常好时，应检查同图泄漏、隐藏点进入输入或插值使用了完整参考数据。增加重复数据包或更换更复杂网络，不能弥补独立空间场景不足。

效果怎样判断

在未参与训练的测试场景上，给三个网络提供同一组输入测点，以其余隐藏实测点为答案。将预测还原到 dBm，报告 MAE、RMSE，误差单位为 dB；同时记录推理时间，并与只使用相同输入点的简单插值方法比较。

改变输入测点数量和空间分布，观察预测误差如何变化。展示输入点、预测热力图和隐藏点误差，使用一致的颜色标尺。图像平滑不等于预测准确，隐藏点的结果也不能证明每个未测像素都准确。测试仅覆盖同一房间的新部署时，应如实限定结论范围。

模型怎样交付

保存最佳权重、模型结构、标准化参数和网格配置，结束训练进程后重新加载。仅提供房间信息与部分测点，确认能够生成整张数值地图，再绘制热力图。推理程序不能读取参考答案，残差方案还应保存插值参数与处理逻辑。

最终提交带坐标的实测数据说明、三个方案的比较结果、可重新加载的模型和演示软件。软件支持导入测点、生成地图及导出结果即可。依据验证表现选择交付模型，最终测试只用于报告效果，不要求神经网络必然优于传统插值。

部署教程 PyTorch 模型保存与加载

阅读与实现重点：先保证数据划分、监督位置和单位正确，再讨论网络改进。所有结果应来自真实运行，具体实现与参数由项目组查阅链接并完成。